

Petits développement autour des estimateurs Statistiques

Il est très rare de trouver une explication claire des différentes constantes utilisées pour les calculs de capabilité. Très souvent on nous renvoie à des tables sans autre explication... Mon propos ici est de donner les grandes lignes qui permettent le calcul de ces constantes.

Bien sûr, il faut quelques pré-requis en mathématique, en particulier être familier avec la loi du χ^2 et la fonction Γ qui n'est rien d'autre qu'une extension de la factorielle aux complexes ([Voir ici](#))

Soit $(X_i)_{1 \leq i \leq n}$ n variables aléatoires indépendantes de même loi (cette hypothèse est essentielle on le verra par la suite))

On rappelle que la variable aléatoire égale à la moyenne est :

$$\bar{X} = \frac{X_1 + X_2 + \dots + X_n}{n}$$

la variable aléatoire égale à la variance des n valeurs est :

$$S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

Si X est distribuée selon la loi normale $\mathcal{N}(\mu; \sigma)$ alors $\bar{X} \hookrightarrow \mathcal{N}(\mu; \frac{\sigma}{\sqrt{n}})$
En effet : $E(\bar{X}) = \frac{1}{n} \sum_{i=1}^n E(X_i) = \frac{n\mu}{n} = \mu$ et

$V(\bar{X}) = \frac{1}{n^2} \sum_{i=1}^n V(X_i)$ (par indépendance) donc :

$$V(\bar{X}) = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}$$

Théorème Central limite : Si n est "grand" alors la loi de \bar{X} se rapproche de la loi $\mathcal{N}(\mu; \frac{\sigma}{\sqrt{n}})$

Soient $(X_i)_{1 \leq i \leq n}$ **n variables iid suivant toutes la loi $\mathcal{N}(\mu; \sigma)$, alors :**

$S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \iff \frac{nS^2}{\sigma^2} = \sum_{i=1}^n \left(\frac{X_i - \bar{X}}{\sigma} \right)^2$
 par conséquent $\frac{nS^2}{\sigma^2}$ suit la loi du $\chi^2(n-1)$ (Loi du chi2)

On sait que $E\left(\frac{nS^2}{\sigma^2}\right) = n-1$ une estimation ponctuelle de la variance σ^2
 est donc $S_{n-1}^2 = \frac{nS^2}{n-1} = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n-1}$

Une autre approche serait d'écrire : $S^2 = \frac{\sum_{i=1}^n X_i^2}{n} - \bar{X}^2$ alors :

$$E(S^2) = \frac{1}{n} \sum_{i=1}^n E(X_i^2) - E(\bar{X}^2) = E(X^2) - E(\bar{X}^2)$$

$$E(S^2) = V(X) + E(X)^2 - (V(\bar{X}) + E(\bar{X})^2) = V(X) - V(\bar{X})$$

$$E(S^2) = V(X) - \frac{1}{n} V(X) = \frac{n-1}{n} V(X) = \frac{n-1}{n} \sigma^2$$

et donc pour éviter le biais $\frac{n-1}{n}$ on prend pour estimateur ponctuel de la variance $S_{n-1}^2 = \frac{nS^2}{n-1}$

Nous avons un estimateur sans biais de la variance mais il ne faut pas penser que sa racine carrée est un estimateur sans biais de l'écart-type...

En effet, posons $K = \frac{nS^2}{\sigma^2} \hookrightarrow \chi^2(n-1)$ de densité :

$$f(t) = \frac{e^{-\frac{t}{2}} t^{\frac{n-1}{2}-1}}{2^{\frac{n-1}{2}} \Gamma(\frac{n-1}{2})}$$

Alors

$$E(\sqrt{K}) = \int_0^{+\infty} \sqrt{t} f(t) dt = \frac{\sqrt{2} \Gamma(\frac{n}{2})}{\Gamma(\frac{n-1}{2})} \iff E(\sqrt{n} S) = \frac{\sqrt{2} \Gamma(\frac{n}{2})}{\Gamma(\frac{n-1}{2})} \sigma$$

$$E\left(\sqrt{\frac{n}{n-1}} S\right) = \sqrt{\frac{2}{n-1}} \frac{\Gamma(\frac{n}{2})}{\Gamma(\frac{n-1}{2})} \sigma$$

On pose :

$$c_4(n) = \sqrt{\frac{2}{n-1}} \frac{\Gamma(\frac{n}{2})}{\Gamma(\frac{n-1}{2})}$$

on alors :

$$E\left(\frac{S_{n-1}}{c_4(n)}\right) = \sigma$$

On donc trouver un estimateur ponctuel de σ : $\hat{\sigma} = \frac{S_{n-1}}{c_4(n)}$

Estimateurs ponctuel de l'écart-type σ d'une population à partir de l'étendue R

Soient $(X_i)_{1 \leq i \leq n}$ n variables aléatoires indépendantes suivant toutes la loi $\mathcal{N}(\mu; \sigma)$.

Les variables centrées réduites seront notées X_i^* de densité φ et de fonction de répartition Φ

L'étendue R (Range en anglais) est définie par :

$$R = \text{Max}_i(X_i) - \text{Min}_i(X_i)$$

On a :

$$\frac{R}{\sigma} = \frac{\text{Max}_i(X_i) - \mu}{\sigma} - \frac{\text{Min}_i(X_i) - \mu}{\sigma}$$

Considérons :

$$M_n = \frac{\text{Max}_i(X_i) - \mu}{\sigma} = \text{Max}_i(X_i^*) \text{ et } m_n = \frac{\text{Min}_i(X_i) - \mu}{\sigma} = \text{Min}_i(X_i^*)$$

La fonction de répartition de M_n est donnée pour tout réel t par :

$$P(M_n < t) = P\left(\bigcap_i X_i^* < t\right) = \prod_i P(X_i^* < t) = (\Phi(t))^n$$

Ainsi, la fonction de densité de M_n , notée f_{M_n} est obtenue par dérivation :

$$f_{M_n}(t) = n\varphi(t) \times (\Phi(t))^{n-1}$$

En outre, $m_n = \text{Min}_i(X_i^*) = -\text{Max}_i(-X_i^*)$ ainsi :

$$\mathbb{E}\left(\frac{R}{\sigma}\right) = 2\mathbb{E}(M_n)$$

On notera $d_2 = 2\mathbb{E}(M_n)$

et on a :

$$d_2 = 2 \int_{-\infty}^{+\infty} nt\varphi(t) \times (\Phi(t))^{n-1} dt$$

soit :

$$\mathbb{E} \left(\frac{R}{\sigma} \right) = d_2$$

Ainsi :

$$\hat{\sigma} = \frac{\bar{R}}{d_2}$$

d_2 et c_4 se calculeront numériquement ou nous utiliserons des tables